

第八届中国研究生人工智能创新大赛

实验方案

TARDIS

时域一致性优化的可复现实验设计与统计协议

团队名称	我是真没招了
参赛组别	企业赛题——基于扩散模型的实时视频生成算法时域一致性优化
核心指标	Temporal Consistency、LPIPS、端到端延迟与资源占用
文档版本	V2.0

2026 年 8 月

目录

1	研究目标、问题与可证伪假设	1
2	任务定义与评估边界	2
3	数据来源、抽样与划分	2
3.1	三个评估来源	2
3.2	预处理与生成条件	3
4	对比系统与公平性协议	3
4.1	九个数值对比系统	3
4.2	五个视觉参考系统	4
5	统一运行条件与测量口径	4
6	评价指标与估计量	5
6.1	时域一致性与感知质量	5
6.2	运动、效率与资源指标	6
6.3	评估循环	6
7	统计推断与多重比较	7
8	实验一：综合质量与时域一致性主对比	7
8.1	假设与实验单位	7
8.2	执行协议	7
8.3	判定准则	8
9	实验二：时域动态、运动与遮挡诊断	8
9.1	短程与长程漂移	8
9.2	运动与场景分层	8
10	实验三：实时延迟、吞吐与资源占用	9
11	实验四：组件归因消融	9

12 实验五：超参数敏感性与稳定工作区间	10
13 实验六：随机性、提示词与输入扰动鲁棒性	11
14 实验七：跨来源、跨基座与跨任务泛化	12
15 实验八：双盲主观评估	13
16 实验九：定性审查与失败案例	13
17 质量控制、停止准则与报告规范	14

1 研究目标、问题与可证伪假设

TARDIS 面向扩散视频生成中的时域漂移、局部闪烁和冗余计算问题。实验设计不以单一均值为终点，而是同时检验生成质量、短程与长程一致性、文本对齐、计算开销、跨来源稳定性和主观偏好。所有主结论均在观测结果之前给出方向、统计单位和失败条件；若置信区间跨越零效应或校正后的显著性水平未通过，则对应假设视为未获支持，而不以定性样例替代数值证据。

核心研究问题如下。

编号	研究问题	主要终点	反证条件
RQ1	TARDIS 是否降低相邻帧的时域不一致	TC、tLPIPS、warp error	视频级差值无显著改善
RQ2	时域改善是否以感知质量下降为代价	LPIPS、FVD、CLIPScore	一致性改善但质量显著退化
RQ3	优势是否跨数据来源和运动强度保持	分层效应量、交互项	仅单一来源或低运动区间有效
RQ4	TAR、商空间投影、风险路由和因果状态是否各自必要	组件消融差值	删除组件不产生可重复变化
RQ5	稀疏创新计算是否形成质量与开销的更优折中	Pareto 前沿、延迟、显存	被同预算基线严格支配
RQ6	性能是否对随机种子、提示词风格和轻度扰动稳健	方差分解、最坏分位数	均值优势由少数有利样本驱动
RQ7	客观指标优势是否与双盲主观偏好一致	混合效应偏好比	主观偏好方向相反或不确定
RQ8	失败模式是否可定位并由明确边界解释	失败率、场景分层	错误无法复现或无稳定触发条件

预注册的主假设为：在相同输入、分辨率、输出长度和评测实现下，TARDIS 相对九个外部对比系统在视频级 TC 与 LPIPS 上取得方向一致的改善，并在 Holm 校正后仍具有统计意义。次假设为：该改善在中高运动、遮挡和长时间间隔条件下仍保持，同时端到端延迟与峰值显存不被质量相近的对比系统严格支配。

2 任务定义与评估边界

实验采用两个严格分离的任务协议。协议 A 为 **source-conditioned** 视频生成或编辑：系统接收源视频、文本条件和可选结构条件，输出与源视频时间对齐的结果。该协议允许计算参考型 LPIPS、赛题 TC 和基于源光流的 warp error。协议 B 为 **prompt-only** 视频生成：系统仅接收文本、采样参数和固定首帧初始化策略，不把源视频作为生成输入；该协议主要使用 tLPIPS、FVD、CLIPScore、闪烁率和主观评估，不把缺少配对参考的 LPIPS 解释为重建质量。

对于能够同时执行两种协议的方法，分别报告两套结果，不跨协议排序。对于只支持其中一种协议的方法，仅进入兼容的比较集合。任何外部论文报告值只用于背景说明，不进入本地复现主表，也不参与显著性检验。由此避免因输入条件、预处理、硬件或采样预算不同而产生不可归因的差异。

统计单位为完整视频，而不是单帧。帧级度量先在单个视频内部聚合，随后在采样种子上聚合，最后在数据来源层面进行配对推断。逐帧记录只用于绘制时间轨迹、定位突发错误和估计视频内变异，不被当作独立样本扩大有效样本量。

3 数据来源、抽样与划分

3.1 三个评估来源

数据来源	公开入口	覆盖重点
DataVerse	Vchitect T2V DataVerse	真实与合成混合场景、镜头运动和主体运动
OpenVid-1M	OpenVid-1M	跨来源视频分布、复杂构图和开放域语义
Seedance prompts	Seedance prompt collection	提示词长度、风格、主体和事件组合的压力测试

DataVerse 与 OpenVid-1M 用于视频条件和开放域生成评估。Seedance 来源提供提示词分布，本身不被当作带配对真值的视频数据；其 **prompt-only** 评估使用预先锁定的中性首帧集合，**source-conditioned** 评估则使用在实验开始前完成语义匹配的固定源视频集合。匹配过程不读取任何待比较系统的输出。

每个来源锁定 50 个测试实例，共 150 个实例。视频实例满足以下纳入条件：可稳定解码、有效长度不少于 32 帧、主体或场景语义可由文本描述、无明显重复片段、无损坏帧和不可判定许可状态。近重复检测同时使用感知哈希与视觉嵌入余弦相似度；同一原视频的裁剪或转码版本不能跨训练、验证和测试划分。

训练与超参数选择只使用训练和验证划分。测试实例在配置冻结后仅运行一次正式评估；任何根据测试表现进行的阈值、窗口长度、采样步数或损失权重调整，

都必须重新建立独立测试划分。若上游来源提供官方划分，则优先采用官方划分；否则按视频身份去重后进行确定性分层划分，并固定随机状态。

3.2 预处理与生成条件

所有系统使用相同的内容裁剪、颜色空间和输出编码规则。视频按短边缩放后中心裁剪为 512×512 ，像素归一化到 $[0,1]$ ；训练窗口为连续 16 帧，正式时域统计使用每段结果的前 30 个有效解码帧。若方法存在原生分辨率限制，则先在原生分辨率生成，再以同一高质量缩放算子映射到评测分辨率，并同时报告原生与统一分辨率结果。

采样随机状态固定为 3407、3413、3433、3469 和 3491。这里的“同种子”只表示每个系统内部的重复索引一致，不声称跨架构潜变量具有相同语义。训练初始化和生成采样随机性分开记录；主对比固定检查点，仅改变生成采样状态。消融研究至少使用三个独立训练初始化，以区分结构贡献与偶然收敛差异。

提示词在比较前完成冻结。每个视频实例对应一个内容提示和一个风格受控提示；提示词长度、负向提示、标点和语言不因方法而改变。需要结构条件的方法从同一源视频计算边缘、深度或运动条件，禁止使用目标输出反向构造条件。

4 对比系统与公平性协议

4.1 九个数值对比系统

编号	对比系统	公开入口	方法类别
1	StreamDiffusion	官方入口	流式少步扩散
2	Rerender-A-Video	论文入口	关键帧传播与视频重绘
3	TokenFlow	官方入口	扩散特征跨帧一致性
4	vid2vid-zero	官方入口	零样本视频编辑
5	Text2Video-Zero	官方入口	零样本文生视频
6	ControlVideo	官方入口	结构条件视频控制
7	StableVideo	论文入口	帧间传播视频编辑
8	AnimateDiff-Lightning	模型入口	少步运动模块
9	SD-Turbo independent	模型入口	独立逐帧下界

TARDIS 作为第十个被评估系统。九个外部系统不是同一任务族，因此公平性采用“双轨报告”。原生质量轨使用各方法公开推荐的稳定设置，反映其可复现最佳工作点；预算匹配轨限制分辨率、输出帧数、batch、设备和允许的扩散网络调用次数，用于比较相近计算预算下的质量。两条轨道均报告，不能只选择对 TARDIS 有利的一条。

基座、条件形式和原生采样器不同的系统不强行替换为同一基座。所有差异均作为方法属性记录；公平性由相同任务输入、相同评测输出、相同硬件测量和双轨预算控制保证。复现失败的系统不以零分填充，也不以论文值替代，而是记录失败阶段、兼容性原因和已尝试的公开推荐设置。

4.2 五个视觉参考系统

视觉参考系统	公开入口	定性审查重点
ZeroScope v2 576w	模型入口	低分辨率主体与背景连续性
Pyramid Flow miniFLUX	官方入口	构图稳定性与快速运动
Transformer-T2V 2B	论文入口	文本语义和中等规模生成能力
ModelScope T2V 1.7B	模型入口	早期开源文生视频参考
Wan2.1 T2V 1.3B	官方入口	现代开源文生视频参考

五个视觉参考系统只进入同提示词、同展示时刻和同裁剪规则的定性审查，不替代九个数值对比系统。抽帧位置由归一化时间 0、0.25、0.50、0.75 和 1.00 预先确定，不能按画面质量手工挑选。clean 视图展示原始帧，annotated 视图只标记主体、物体、场景区域和时域错误，不改变像素内容。

5 统一运行条件与测量口径

正式训练在单张 NVIDIA RTX 4090 24 GB 上完成，正式推理和部署测量在单张 NVIDIA RTX 5060 8 GB 上完成。训练采用 bf16 AMP、micro batch 1、梯度累计 4、validation batch 2、AdamW、峰值学习率 1e-4、weight decay 1e-2、线性 warmup 后 cosine decay、全局梯度裁剪 1.0 和 EMA 0.999。冻结的视觉先验不参与 EMA；检查点仅由 validation TC 与 LPIPS 的预注册组合分数选择。

推理统一设置 batch 1。TARDIS 使用两次 endpoint update、active ratio 0.35、因果状态缓存和 VAE slicing；其他方法在原生质量轨使用公开推荐设置，在预算匹配轨使用预先规定的网络调用预算。输出 metadata 帧率固定为 30 FPS，但该字段不被解释为真实生成吞吐；真实速度由 GPU 同步后的端到端墙钟时间计算。

延迟测试先执行 20 次不计入统计的预热，再连续测量 500 个有效生成窗口。每次计时前后执行 GPU 同步，分别记录首帧延迟、稳态单帧延迟、完整视频时间、编码时间和数据传输时间。主报告给出 P50、P95、P99、均值、标准差和 95% 置信区间；峰值显存由设备峰值分配统计获得，并在每次配置前重置。

控制维度	正式设置	公平性要求
空间分辨率	512×512	同轨比较保持一致
有效分析长度	30 帧	不足长度视为失败而非补帧
训练窗口	连续 16 帧	仅影响可训练系统
生成重复	5 个固定采样状态	视频级配对聚合
推理 batch	1	延迟和显存统一测量
数值精度	bf16, 必要时 fp16	精度变化必须单独标记
提示词	逐实例固定	不做方法特定改写
结果选择	全量结果	禁止挑选最好种子

6 评价指标与估计量

6.1 时域一致性与感知质量

在 source-conditioned 协议中，赛题 TC 定义为输出变化与源视频变化之间的平均 L1 偏差。设源视频为 $X_{1:T}$ 、输出为 $Y_{1:T}$ ，则

$$\text{TC}(X, Y) = \frac{1}{T-1} \sum_{t=1}^{T-1} \|(Y_{t+1} - Y_t) - (X_{t+1} - X_t)\|_1.$$

较低 TC 表示输出遵循源运动，但静态复制也可能获得较低值，因此必须与 LPIPS、CLIPScore、运动幅值保持率和人工语义检查联合解释。LPIPS 在配对参考可用时逐帧计算后进行视频内平均；prompt-only 协议不构造虚假的配对参考。

光流 warping error 使用源视频相邻帧估计正向流 $F_{t \rightarrow t+1}$ ，将 Y_t 双线性变换到 $t+1$ 时刻，并在非遮挡区域计算与 Y_{t+1} 的差异。tLPIPS 在相同遮挡掩码下计算变换后特征距离。遮挡掩码由前后向流一致性获得，避免把新显露区域错误计为时域破坏。

指标	方向	适用协议	解释边界
TC	越低越好	source-conditioned	必须联合内容与运动保持率
LPIPS	越低越好	有配对参考	不能用于无参考 prompt-only 重建解释
tLPIPS	越低越好	两种协议	使用遮挡感知的运动对齐
Flow warp error	越低越好	两种协议	对光流估计误差敏感
Flicker rate	越低越好	两种协议	阈值由 validation 分布校准
CLIPScore	越高越好	两种协议	衡量文本语义，不等价于画质
FVD	越低越好	prompt-only 为主	需要足够视频样本和统一特征提取
SSIM	越高越好	有配对参考	作为结构诊断而非唯一主指标

6.2 运动、效率与资源指标

运动幅值以图像对角线归一化，避免固定像素阈值随分辨率变化。根据 validation 分布的四分位数形成低、中低、中高和高运动四档。长程一致性在 lag 1、2、4、8 和 16 上计算遮挡感知的特征漂移；所有 lag 均换算为秒并同时报告，以避免不同 FPS 造成误解。

效率指标包括首帧延迟、稳态 P50/P95/P99、完整视频墙钟时间、实测吞吐、峰值显存、扩散网络调用次数、active-token 比例和输出编码开销。30 FPS 的 33.3 ms 仅作为服务目标参考线；若当前硬件未达到该阈值，结果必须如实报告为质量优先工作点。

6.3 评估循环

下列伪代码表达统计层级。其目的不是规定某个实现，而是保证帧级观测不会被错误地当作独立视频。

```

for source in evaluation_sources:
    for instance in locked_test_instances[source]:
        for system in compatible_systems(instance.protocol):
            seed_scores = []

```

```

for seed in generation_seeds:
    video = generate(system, instance, seed)
    frame_scores = evaluate_frames(video, instance)
    seed_scores.append(aggregate_within_video(frame_scores))
    record_video_unit(source, instance, system, mean(seed_scores))

paired_inference(unit="video", stratify_by="source")

```

7 统计推断与多重比较

主比较使用相同视频实例上的配对差值。对每个数据来源分别估计均值差、中位数差、百分比改善和 95% 配对 bootstrap 置信区间，bootstrap 以视频为重采样单位并重复 10,000 次。连续指标优先使用配对置换检验；分布明显偏斜时同时报告 Wilcoxon signed-rank 检验和 rank-biserial effect size。

TARDIS 与九个外部系统的主终点比较采用 Holm 方法控制 family-wise error rate，双侧显著性水平为 0.05。方向性假设仍使用双侧检验，避免在意外退化时降低惩罚。除校正后的 p 值外，必须同时报告效应量和置信区间；仅有统计显著而无实际效应的差异不能写成实质领先。

跨数据来源结论采用混合效应模型，系统和运动档为固定效应，视频身份和生成采样状态为随机截距；必要时加入系统 × 来源和系统 × 运动档交互项。若交互显著，则按来源给出分层结论，不以总体均值掩盖局部失败。

预注册的最小实际效应阈值为：TC 或 LPIPS 相对改善至少 2%，且 95% 置信区间不跨零；延迟改善至少 5%，或在质量不劣于 1% 的约束下形成新的 Pareto 点。阈值用于解释实际意义，不替代完整统计量。

8 实验一：综合质量与时域一致性主对比

8.1 假设与实验单位

主实验检验 RQ1、RQ2 和 RQ3。实验单位为一个锁定视频实例在五个生成采样状态上的均值。每个来源包含 50 个实例；对兼容的十个系统进行评测时，最大规模为 $3 \times 50 \times 10 \times 5$ ，即 7,500 段生成结果。若某系统不支持特定协议，该单元不进入该协议的配对总体，且分母随表格明确给出。

8.2 执行协议

对每个实例，所有系统接收相同 prompt、源视频或固定首帧条件、输出长度与分辨率。运行顺序在系统和实例维度随机化，以降低温度、缓存和后台负载随时间变化造成的偏差。每次生成前清空方法特有的跨视频状态；同一视频内部允许使用该方法定义的因果缓存。

原生质量轨和预算匹配轨独立执行。原生质量轨回答“公开推荐工作点的质量如何”，预算匹配轨回答“相近网络调用和设备约束下的效率如何”。主表同时呈现两轨，不能把一条轨的质量与另一条轨的延迟拼接为同一工作点。

8.3 判定准则

TC 与 LPIPS 为预注册联合主终点。在适用协议内，只有当二者相对九个外部系统的配对方向均不退化，并且至少一个主终点通过 Holm 校正与最小实际效应阈值时，才称为“全面领先该对比系统”。若 TC 改善但 LPIPS 退化，结论必须写为质量—一致性权衡。

次终点包括 tLPIPS、warp error、CLIPScore、FVD、SSIM、失败率和最坏 10% 视频分位数。最坏分位数用于检查均值是否由少数容易场景主导。每项结果按数据来源分层，并提供视频级差值分布。

9 实验二：时域动态、运动与遮挡诊断

9.1 短程与长程漂移

对每个视频保留逐帧 TC、tLPIPS、亮度变化和运动保持率序列。报告从第 2 帧到第 30 帧的均值曲线及视频级 bootstrap 带，并计算前 1/3、中 1/3 和后 1/3 的分段斜率。若后段误差持续上升，说明因果状态积累存在长期漂移，即使全局均值较低也不能判定稳定。

长程特征漂移在 lag 1、2、4、8、16 上测量。每个 lag 仅使用两端均可见的像素或特征区域，并按实际时间间隔归一化。比较 TARDIS、最强两项外部系统、最快外部系统和逐帧下界，检验因果记忆是否只改善相邻帧，还是延伸到更长时间尺度。

9.2 运动与场景分层

运动强度按归一化光流四分位数划分。场景类型由两名不了解方法身份的标注者独立标注为镜头运动、刚体目标运动、非刚体形变、遮挡/显露和场景切换；允许多标签。分歧由第三名标注者裁决，并报告 Cohen's kappa。

分层因素	水平	主要检查
运动强度	四个分位档	优势是否随运动增强消失
遮挡比例	低、中、高	新显露区域是否产生闪烁
时间位置	前、中、后段	因果误差是否随时间累积
场景类型	五类多标签	方法优势的适用范围
纹理频率	低、中、高	高频纹理是否被过度平滑

该实验的成功条件不是所有分层均显著，而是总体主效应保持且不存在方向反转的关键交互。若只在低运动或无明显遮挡时有效，则结论必须限定到对应场景。

10 实验三：实时延迟、吞吐与资源占用

效率实验在 RTX 5060 8 GB 上进行，batch 固定为 1。每种配置执行 20 次预热和 500 次有效测量，随机交替系统顺序；测量期间固定电源模式、时钟策略和后台进程。端到端时间从条件准备开始，到可播放帧或完整视频写入编码缓冲结束，同时保留纯 GPU 核心时间用于定位瓶颈。

分辨率设置为 256、512 和 768，输出长度设置为 16、30 和 60 帧。分辨率和长度只在方法支持范围内测试，不进行隐式补帧。报告首帧延迟、稳态 P50/P95/P99、吞吐、峰值显存、OOM 率和编码占比。

因素	水平	固定条件	统计摘要
分辨率	256、512、768	batch 1、相同帧数	P50/P95/P99、显存
输出长度	16、30、60 帧	512×512	总时间、稳态斜率
精度	bf16、fp16	相同工作点	延迟、数值稳定性
active ratio	0.20 至 1.00	TARDIS 两步更新	质量—开销曲线
并发负载	1、2 个请求	相同总设备	尾延迟和排队时间

质量—开销 Pareto 判定同时使用 TC、LPIPS 和 P95 延迟。若某配置在三项上均不优于另一配置且至少一项严格更差，则视为被支配。33.3 ms 参考线仅用于显示与 30 FPS 服务目标的距离，不把输出编码的 FPS metadata 当作实测吞吐。

11 实验四：组件归因消融

消融只在 validation 上选择超参数，最终配置在锁定测试实例上重新评估。每个主要消融使用至少三个独立训练初始化和五个生成采样状态。删除组件时保持训练步数、优化器、数据顺序和参数更新预算一致；若删除后参数量显著下降，则同时提供参数匹配的容量控制。

变体	改动	对应机制假设	预期诊断
TARDIS full	全部模块开启	完整方法	主参考点
w/o TAR	移除传输对齐残差化	历史状态需要运动对齐	warp error 和 TC 上升
w/o TOQ	不做轨道商空间投影	切向与法向创新需解耦	冗余残差和漂移增加
dense innovation	active ratio 固定为 1	风险路由负责稀疏预算	开销上升而质量收益有限
w/o causal state	每帧重置长期状态	因果记忆支撑长程稳定	大 lag 漂移增加
w/o CIOD	移除因果创新蒸馏	少步学生需要算子监督	少步工作点退化
w/o metric alignment	移除指标对齐阶段	后训练改善目标指标	TC/LPIPS 改善减弱
no EMA evaluation	使用即时权重	EMA 降低训练噪声	跨种子方差增加

组件贡献以 full 与相应变体的视频级配对差值报告。不能把某个消融变体直接等同于外部系统，因为两者在训练轨迹、参数量和条件机制上并不相同。若组件删除没有稳定负效应，则该组件的必要性主张应被弱化，并讨论是否只在特定场景生效。

12 实验五：超参数敏感性与稳定工作区间

敏感性实验检验方法是否依赖单一精调点。所有扫描先在 validation 完成，再将预注册的中心点和边界点应用于测试。每个扫描只改变一个因素，其余训练和推理条件固定。

因素	扫描水平	主要响应	选择规则
endpoint updates	1、2、4、8	TC、LPIPS、延迟	质量—开销 Pareto
active ratio	0.20、0.35、0.50、 0.75、1.00	稀疏度、尾延迟、 质量	不劣约束下最低开 销
状态窗口	2、4、8、16、32	lag 漂移、显存	长程稳定与内存折 中
TC loss 权重	1、3、5、7	TC、静态偏置	防止以运动衰减换 一致性
LPIPS loss 权重	1、2、3、5	感知质量、纹理闪 烁	联合主终点最优区 间
EMA decay	0.99、0.995、 0.999、0.9995	方差、收敛速度	validation 稳定性

除均值曲线外，报告局部斜率和跨训练初始化标准差。若中心工作点两侧轻微变化就导致主指标方向翻转，则方法被视为参数敏感，不能只展示最优点。若存在宽阔平台，则平台中心优先于边界最优点，以提高部署稳定性。

13 实验六：随机性、提示词与输入扰动鲁棒性

随机性分析将总变异拆为视频身份、训练初始化和生成采样状态三层。主对比的五个采样状态用于估计生成随机性；组件研究的三个训练初始化用于估计优化随机性。报告组内相关系数、方差分量和最坏采样状态下的性能。

提示词分为简短名词短语、完整事件句、风格增强句和含多主体关系的复杂句。每类在三个来源中保持相同数量，并控制平均 token 长度。输入扰动包括亮度变化、轻度高斯噪声、JPEG 压缩和 1% 至 3% 的空间平移；扰动强度在不改变主要语义的范围内预先固定。

鲁棒性维度	水平	主要终点	失败判定
生成采样状态	5 个固定状态	视频级方差、最坏分位数	优势仅出现在少数状态
训练初始化	3 次独立训练	均值与方差分量	结构收益小于优化方差
提示词类型	4 类	CLIPScore、TC、失败率	复杂关系导致方向反转
噪声扰动	3 个强度	相对性能下降	轻度扰动引发显著崩溃
视觉来源	真实、合成、卡通	分层效应量	仅单一视觉域有效

鲁棒性结果以相对退化率而非只看绝对值。若所有方法都因扰动变差，关键问题是 TARDIS 的退化斜率是否更小；若干净输入领先但扰动后落后，则不能宣称稳定泛化。

14 实验七：跨来源、跨基座与跨任务泛化

跨来源评估使用未参与训练与 validation 的视频集合，并保持与主测试相同的纳入规则。跨基座实验只替换冻结视觉先验，重新训练 TARDIS 的时域模块，不直接加载结构不兼容的权重。跨任务评估覆盖风格迁移、局部编辑、目标替换和 prompt-only 生成，分别使用与任务兼容的指标。

泛化轴	训练条件	测试条件	关注结论
跨数据来源	单一来源训练	其余来源测试	分布迁移下的时域稳定性
跨视觉域	真实视频为主	合成与卡通	纹理和运动统计变化
跨基座	固定时域设计	三种兼容先验	方法是否依赖单一先验
跨任务	视频编辑训练	四类生成任务	机制是否超出单一任务

所有泛化结论同时报告域内和域外差距。若域外下降显著，但仍优于相同设置下的外部系统，可称为相对稳健；若域外优势消失，则只保留域内结论。不能用域内调参结果反复优化域外测试。

15 实验八：双盲主观评估

主观实验比较 TARDIS 与 StreamDiffusion、Rerender-A-Video 和 TokenFlow。每个数据来源随机抽取 20 个实例，共 60 个刺激；每个比较对保持相同 prompt、显示尺寸、编码参数和播放次数。左右位置、系统顺序和刺激顺序按 Latin-square 平衡，界面不显示方法名称。

计划招募不少于 24 名具有正常或矫正后正常视力的成年人。开始前取得知情同意，不收集可直接识别身份的信息。纳入规则、退出规则和注意力检查在观察结果前固定；未通过两项以上注意力检查的参与者整体排除，而不是按单个不利评分选择性删除。

强制选择任务分别询问时域流畅度、画面质量、文本一致性和综合偏好。若报告 MOS，则另设 1 至 5 分 Likert 量表，不把强制选择编码为 MOS。强制选择使用参与者和刺激双随机截距的混合效应 logistic 回归；Likert 评分使用累积链接混合模型或参与者聚类 bootstrap。报告胜率、odds ratio、95% 置信区间和多重比较校正结果。

功效分析以最小可检测胜率 60%、双侧 0.05 和 80% power 为目标，并按参与者内相关性上调样本量。若最终有效参与者数量不足预注册要求，主观结论标为探索性，不与客观主终点合并为确定性结论。

16 实验九：定性审查与失败案例

定性结果采用固定 prompt、固定归一化时间点和固定裁剪，不按画面美观程度选择。每个场景同时给出 clean 与 annotated 视图：clean 视图用于观察真实输出，annotated 视图用不同颜色标记人物、物体、场景背景、遮挡区域和明显闪烁位置。标注标签只描述可见现象，不把 TC 或 LPIPS 数值伪装成目标检测置信度。

审查重点包括主体身份漂移、局部纹理闪烁、背景几何扭曲、遮挡后重现、快速运动拖影、场景切换残留和过度平滑。对每种失败类型统计发生视频比例和平均持续帧数，并与对应的时域轨迹对齐。成功样例与失败样例使用同一选择规则，避免只展示有利结果。

失败类型	操作定义	对应诊断
身份漂移	主体关键属性跨帧不可逆改变	区域 LPIPS、人工一致性
局部闪烁	静态区域出现高频亮度或纹理跳变	flicker rate、tLPIPS
几何扭曲	背景直线或物体形状无运动依据地变形	warp error、结构标注
遮挡恢复失败	目标重新显露后身份或位置错误	遮挡分层 TC
运动衰减	输出显著弱化源运动以降低 TC	运动保持率
场景切换残留	新场景保留旧场景纹理或状态	切换后漂移曲线

17 质量控制、停止准则与报告规范

实验开始前冻结数据划分、提示词、五个生成采样状态、主要终点、显著性水平、校正方法和异常处理规则。异常值不因其数值大小自动删除；只有解码失败、设备故障、输出长度不足或明显违反预定义协议时才排除，并同时报告意向评估结果与有效运行结果。任何排除都保留原因和系统身份，避免结果依赖性清理。

单次配置出现非有限损失时立即停止该次训练，检查 AMP、梯度范数和输入有效性；连续三次独立初始化均失败，则该配置标记为训练不稳定。正式推理若 OOM 或超出 30 分钟任务上限，记录为失败，不以降低分辨率后的结果替换原设置。硬件测量若温度、时钟或后台负载超出预设范围，则整组重新测量。

每个核心结论必须同时具备以下证据：明确协议、视频级样本量、中心趋势、离散程度、95% 置信区间、效应量、校正后的显著性结果以及至少一种分层或失败案例分析。图形展示保留完整分布或视频级点云，不只给柱状均值；折线置信带以视频为重采样单位，不能使用帧级标准误制造过窄区间。

最终结论按证据强度分为“支持”“部分支持”和“未支持”。只有在三种来源上方向一致、联合主终点不退化、统计门槛通过且无关键反向交互时，才使用“全面领先九个外部对比系统”的表述。任何未达到条件的情况均按实际结果限定数据来源、任务协议或计算预算，确保实验叙事可审计、可复现且可证伪。

负结果采用与正结果相同的报告粒度。若某个外部系统在特定来源或运动档显著优于 TARDIS，应保留该分层结果并检查其输入条件、运动保持率和感知质量，而不能将其合并进总体均值后省略。若消融方向与机制假设相反，则首先复核训练稳定性、容量变化和评测实现；复核后仍成立时，机制解释必须随证据更新。

所有主指标在正式比较前通过三类单元审查：恒等输出用于检查参考型指标的零点，时间打乱输出用于检查时域指标的方向，静态复制输出用于检查 TC 是否被无运动解投机。只有当指标对这三类构造例表现出预期排序时，才进入正式统计。对于光流相关指标，还需在合成已知位移和人工遮挡序列上验证 warp 方向、坐标单位与遮挡掩码。

统计复核由两条独立路径完成。第一条从视频级汇总重新计算均值、分位数、置信区间和校正后的显著性结果；第二条从随机抽取的视频重新计算帧级 TC、LPIPS 和运动对齐误差。两条路径的容许数值误差预先设为 $1e-6$ （确定性聚合）或 $1e-4$ （浮点特征度量）。超出容许误差时暂停结论生成，直到定位精度、解码或聚合差异。

在最终报告中，每个实验依次陈述研究问题、协议、样本量、固定变量、估计量、统计结果、失败案例和适用边界。主表只含本地同协议复现结果，定性展示只承担现象解释，不替代视频级统计。该顺序保证论点由预先定义的实验支撑，而不是由少量视觉样例或事后挑选的工作点驱动。